

Cloudflare AI Gateway 實戰課程

從零打造一個跑在邊緣的 AI 對話助理 — 含 MCP 工具整合

講師: Victor Lin · 樂雲智能 解決方案事業部

對象: 15 學員 · 已具備 TypeScript / React 基礎

90 min Live Code Walk + Hands-on Workshop

Edge × Governance × Speed.

AGENDA | 提案大綱

Cloudflare AI Gateway 概論

01



15 min — 痛點 + 三大能力 + BYOK 機制

實作專案架構導覽

02



25 min — Code Walk 8 支 src + D1 schema

動手實作

03



45 min — 4 階段部署你自己的 AI Bot

Q&A + 延伸方向

04



15 min — 自學地圖 + 研究議題探索

WHY AI GATEWAY | 為什麼需要 AI Gateway：企業 AI 三大痛點

直接呼叫 OpenAI / Anthropic 一切都好，直到企業內 100 人同時用 AI 的那天

痛點 1

安全 — API Key 散落、無法即時撤銷

工程師把 API Key 寫進前端、commit 進 git、貼到 Slack。一旦外洩，要追到誰用了什麼 model、產生什麼成本、生成什麼回應，完全沒有日誌。

企業 LLM Key 洩漏率

38%

痛點 2

成本 — 帳單失控、無法分攤

OpenAI 一張帳單、Anthropic 一張帳單、Google 一張帳單。月底結算才發現某部門燒掉 NT\$50 萬，但無法知道是「誰、什麼時候、跑了什麼 prompt」。

AI 成本超支事件比例

67%

痛點 3

治理 — 無 Guardrails、無稽核

員工把客戶 BOM 表貼進 ChatGPT 翻譯、把產品設計圖貼進 Gemini 詢問。沒有任何過濾機制，也無法事後追查哪些敏感資料外流到 LLM。

AI 資料外洩年增率

+340%

CLOUDFLARE AI GATEWAY | Cloudflare AI Gateway — 一行 URL 修改解決三大痛點

統一管理

51+ LLM

原本 : <https://api.openai.com/v1/...> → 改成 :
<https://gateway.ai.cloudflare.com/v1/{account}/{gw}/openai/v1/>



BYOK

Bring Your Own Key

- API Key 由 Gateway 後端保管
- 透過 alias 呼叫，不出現在 Worker
- 可即時撤銷單一 alias
- 支援 Anthropic / OpenAI / Google / Mistral



Analytics

Cost / Token / Latency

- 每次請求自動記錄
- 部門 × 專案 cost 分攤
- 30 天趨勢儀表板
- 異常告警 + 月度報告



Guardrails

Policy + DLP

- Policy 部門 / 職級 / 專案分組
- 自動偵測 PII / 機密關鍵字
- 違規請求自動攔截
- Prompt injection 防護



Cache

Performance + Cost

- 相同請求直接回 cache
- 0 成本、<10ms 回應
- 可設定 TTL
- 降低 LLM 帳單 30-60%

BYOK MECHANISM | BYOK 機制 — 為什麼 API Key 不會進 Worker ?

Worker 只送 alias 名稱 · Gateway 後端依 alias 注入真實 API Key 給 provider

✗ 現況 As-Is

傳統做法 (不安全)

- ▶ Worker 內存 OPENAI_API_KEY secret
- ▶ 請求 header : Authorization: Bearer sk-...
- ▶ API Key 出現在每個 worker request
- ▶ 一旦 worker 程式碼被看到 → 金鑰外洩
- ▶ 無法針對單一專案撤銷金鑰

🔴 高風險 Key 直接在 Worker

🔴 全有全無 撤銷只能整把換

✓ 目標 To-Be

BYOK 做法 (安全)

- ▶ Gateway Dashboard 設定 alias: "claude_demo"
- ▶ Worker header: cf-aig-byok-alias: claude_demo
- ▶ Gateway 後端依 alias 注入真實 sk-...
- ▶ Worker 完全看不到真實金鑰
- ▶ 可針對單一 alias 即時撤銷

✓ 隔離 Key 永遠不出 Gateway

✓ 細粒度 單一 alias 即時撤銷

02

實作專案架構導覽

Code Walk · 8 支 src + D1 schema + 前端兩頁

ARCHITECTURE | 整體架構：1 Worker + D1 + KV + AI Gateway + MCP

全程跑在 Cloudflare 邊緣，無需自建任何伺服器 — 學員今天就能複製這個架構

 學員瀏覽器 (Chrome / Safari)

Cloudflare Pages — frontend (React + Vite)
ChatPage + McpManagerPage + LoginPage

Cloudflare Worker — aigw-course-api (TypeScript)
index.ts (路由) → auth.ts / chat.ts ★ / mcp.ts ★
middleware.ts (CORS + JWT + rate limit) utils.ts (JWT / PBKDF2)

D1 SQLite

users / refresh_tokens
conversations / chat_messages

KV Namespaces

SESSIONS
(MCP token / 暫存)
RATE_LIMITS

AI Gateway + MCP

BYOK → Anthropic
MCP → Cloudflare Docs

★ chat.ts + mcp.ts 是課程核心 — 包含 AI Gateway BYOK 呼叫與 MCP 工具自動 routing 邏輯。

SOURCE STRUCTURE | Worker 8 支 src — 每個檔案做什麼

總共約 1,000 行程式碼 — 學員上完課可在自己專案複製貼上

	檔案	行數	核心職責
index.ts	~80 行	請求進來後第一站	11 條 route → 對應 handler
types.ts	~80 行	型別宣告中心	Env interface 宣告所有 binding
utils.ts	~130 行	底層 helper	JWT (HMAC) + PBKDF2 + base64url
middleware.ts	~80 行	請求預處理	CORS + JWT 驗證 + rate limit
auth.ts	~120 行	帳號認證	register / login / refresh / 失敗鎖定
chat.ts ★	~200 行	AI 對話核心	BYOK 呼叫 + tool calling agentic loop
mcp.ts ★	~110 行	MCP server 管理	list / list-tools / save-token / disconnect
mcp-client.ts	~100 行	MCP 協議實作	JSON-RPC over HTTP + SSE parser

CODE WALK — BYOK | chat.ts 關鍵段：BYOK header 三明治

一個函式就讓你的 Worker 變成「企業級 AI 治理閘道」的客戶端

```
function anthropicHeaders(env: Env): Record<string, string> {
  return {
    'Content-Type': 'application/json',
    'cf-aig-authorization': `Bearer ${env.CF_AI_GATEWAY_TOKEN}`, // ← Gateway 自己的 token
    'cf-aig-byok-alias': env.ANTHROPIC_BYOK_ALIAS ?? 'claude_demo', // ← alias 名稱
    'anthropic-version': '2023-06-01',
  };
}

// 呼叫時：
const res = await fetch(
  `https://gateway.ai.cloudflare.com/v1/${env.CF_ACCOUNT_ID}/${env.CF_AI_GATEWAY_ID}/anthropic/v1/messages`,
  { method: 'POST', headers: anthropicHeaders(env), body: JSON.stringify(reqBody) },
);
```

注意 1

請求 header 完全看不到真實的 Anthropic API Key (sk-ant-xxx) — 那把鑰匙存在 Gateway 後端，由 alias 對應注入。

注意 2

URL 路徑包含 account/gateway/provider 三段 — provider 改成 openai、google 即可切換模型廠商，介面不變。

注意 3

Gateway 自動記錄這次呼叫的 cost / tokens / latency / 是否觸發 guardrails — 全部進 Dashboard 報表。

MCP TOOL CALLING FLOW | MCP 工具呼叫流程：AI 怎麼知道要打哪個工具？

Agentic Loop — 最多 5 輪，AI 自行決定何時呼叫工具、何時回答使用者

①

使用者問問題
「幫我查 R2 的最新功能」

②

Worker 呼叫 mcpListTools
→ 取得 cloudflare-docs MCP 提供的所有工具

③

把工具描述 + 使用者訊息送到 Claude
Claude 回應「我要呼叫 search_docs(query=R2)」

④

Worker 用 mcpCallTool 打到 MCP server
收到工具回傳的文件內容

⑤

把工具結果送回 Claude (同對話)
Claude 根據結果產出自然語言回答

⑥

存進 D1 chat_messages
回傳給前端 UI

03

動手實作 — 4 階段

45 分鐘從 0 部署你自己的 AI Bot

HANDS-ON ROADMAP

下載Codex並複製repo <https://github.com/victor-workspace/cloudflare-aigw-course.git>

 Microsoft | Store

[首頁](#) | [應用程式](#) | [遊戲](#) | [佈景主題](#) | [關於](#)



Codex

OpenAI

3.6 ★ | 11 個評等 | [開發人員工具](#)

 使用 AI 功能

The official Codex desktop app from OpenAI is your command center for agentic software development

[下載](#)

 在 Microsoft Store 中檢視

[家長控制項資訊](#)

 3+ App 內購買

← → 檔案 編輯 檢視 視窗 說明

新聊天
搜尋
外掛程式
自動化
專案
cloudflare-aigw-course

部署環境並讀取 repo ...
幫我讀取repo 並幫我執行環境部署
適用於 4m 24s >

樂雲 AIGW Course Chat MCP 工具管理 Logout

+ 新對話

台灣科技大學

我注意到您提到「台灣科技大學」，但這似乎與 Cloudflare 的文件或服務無關。
我是一個針對 **Cloudflare 文件和產品** 的助手，可以幫助您了解：
- **計算服務**：Workers、Pages、Functions
- **存儲和數據**：R2、D1、KV、Durable Objects
- **AI 服務**：Workers AI、Vectorize、AI Gateway
- **安全和網絡**：Zero Trust、Access、Tunnel、DDoS 防護
- **CDN 和性能**：緩存、DNS、圖像優化
以及其他 Cloudflare 產品
如果您有關於 Cloudflare 的問題，或需要幫助設置和使用 Cloudflare 的服務，我很樂意幫忙！請告訴我您想了解什麼。
1141 tokens

輸入訊息 (Enter 送出 / Shift+Enter 換行) 送出

HANDS-ON ROADMAP | 4 階段部署 — 跟著做就完成

前置作業已完成的學員 → 全程約 30 分鐘，剩下 15 分鐘可玩 MCP 工具



WHAT'S NEXT | 延伸自學地圖 + 研究議題

從 Repo 出發 — 課後可以自己玩到什麼程度，以及學術界正在做的相關研究

工程延伸 (直接動手)

加 RAG	Vectorize index + @cf/baai/bge embeddings · AI 查內部文件
串流輸出	fetch + ReadableStream · 前端打字機效果
Telegram Bot	多開一個 worker 接 webhook · AI 進 LINE / TG
多租戶	users 加 tenant_id · policy 依租戶隔離
Cron 任務	wrangler.toml [triggers] · 每日自動報表

研究議題 (適合論文 / 期末專題)

LLM Routing	依語意難度動態分流到不同 model · 最佳化成本/品質
Cost-aware Caching	語義 cache : 近義 prompt 命中策略與失效機制
Guardrail Evaluation	PII 偵測 FP/FN 評估、prompt injection benchmarking
Agentic Safety	MCP tool injection 攻防、agent loop 終止條件分析
Edge AI Policy	邊緣節點上的分散式 policy enforcement 與一致性

若以本 repo 為基礎做研究專題，歡迎來信討論：victor@leyun.cloud · 樂雲可提供技術討論窗口與 Cloudflare 帳號額度建議。

LEYUN

感謝參與

Thank You



+886-2-77220055



www.leyun.cloud



victor@leyun.cloud

Cloudflare AI Gateway 實戰 · 樂雲智能 LEYUN

帶走 Repo 持續延伸學習

README · QUICK-START · COURSE-OUTLINE · cheatsheet 一應俱全

NEXT STEP — Repo 持續開放，歡迎 **issue / PR** / 研究議題討論

github.com/victor80122/cloudflare-aigw-course · MIT License · 任意衍生